

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE**

**Fakulta informatiky a informačných technológií**

# **Optimalizácia konfiguračných parametrov predikčných metód**

**BAKALÁRSKA PRÁCA**

**2016**

**Matúš Cuper**

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE**

**Fakulta informatiky a informačných technológií**

# **Optimalizácia konfiguračných parametrov predikčných metód**

**BAKALÁRSKA PRÁCA**

Študijný program:

Číslo študijného odboru:

Názov študijného odboru:

Školiace pracovisko:

Vedúci záverečnej práce:

**Bratislava 2016**

**Matúš Cuper**

# Obsah

<b>1</b>	<b>Analýza predičných algoritmov</b>	<b>3</b>
1.1	Lineárna regresia . . . . .	3
1.1.1	Multiple regression model . . . . .	3
1.2	Support vector regression . . . . .	3

# Úvod

Časový rád je množina dátových bodov namenraná v čase postupne za sebou. Matematicky je definovaný ako množina vektorov  $x(t)$ , kde  $t$  reprezentuje uplynulý čas. Premenná  $x(t)$  je považovaná za náhodnú premennú. Merania v časových radoch sú usporiadané v chronologicky správnom poradí.

Trendová zložka predstavuje smer veličiny v dlhodobom horizonte a máva klesajúci alebo stúpajúci charakter. Na druhej strane, sezónna zložka má cyklický charakter a dĺžka cyklu sa viaže napr. ku dňu, týždnu či roku. Nepravidelná zložka reprezentuje náhodné zmeny v prostredí, ktoré nie sú relevantné pre predpoveď časových rádov. Pri trénovaní modelu sa ich snažíme odfiltrovať optimálnou mierou natréňovania modelu.

Cieľom predikcií časových rádov je predpovedať hodnotu premennej v budúcnosti na základe doteraz nameraných dátových vzoriek. Preto je potrebné nájsť funkciu, ktorá predpovedá hodnotu časového rádu v budúcnosti konzistentne a objektívne[2].

Pri predpovedaní časových rádov ako napr. meraní odberu elektriky vznikajú 2 typy tvz. Concept drift. **Concept drift** je zmena správania veličiny, ktorú sa snažíme predpovedať. Model sa tak stáva postupne nepresný a je potrebné aby sa tejto zmene prispôbil. Prvým typom je trvalá alebo dočasná zmena spôsobená ekonomickými alebo ekologickými faktormi. Druhým typom je sezónna zmena, spôsobená zmenami ročných období a množstvom denného svetla. Sezónnu zmenu môžeme pozorovať na úrovni dní, týždňov alebo rokov. Kvôli tomu je nutné v každom modeli rozdeľovať tieto 2 typy concept drift[3].

# Kapitola 1

## Analýza predičných algoritmov

Na základe množstva predikčných

### 1.1 Lineárna regresia

bars co

#### 1.1.1 Multiple regression model

Viacnásobná regresia sa pokúša modelovať vzťah medzi dvoma alebo viacerými nezávislými premennými a závislou premennou vhodnou lineárnou rovnicou pre pozorované dáta. Výsledný model je vyjadrený ako funkcia viacerých nezávislých premenných a predpoveďou nie je priamka ako je to pri lineárnej regresii[3]. Nezávislé premenné môžu predstavovať meteorologické vplyvy, ekonomický rast, ceny elektriky či kruzy mien[4].

### 1.2 Support vector regression

Support Vector Machine a Support Vector Regression sú založené na štatistickej teórii učenia, nazývanej aj VC teória, podľa svojich autorov, Vapnik a Chervonenkisa.

Support Vector Machine je použité na množstvo úloh strojového učenia ako je rozoznávanie vzorov, klasifikácia objektov a v prípade predikcií časových rádov to je regresná analýza. Support Vector Regression je postup, ktorého funkcia je predpovedaná pomocou nameraných dát, ktorými je Support Vector Machine postupne natrénované. Toto je odklon od tradičných predpovedí časových rádov, v zmysle, že Support Vector Machine nepoužíva žiadny model, ale predikciu riadia samotné dáta[2].

# Literatúra

- [1] “Time series analysis: The basics.” <http://www.abs.gov.au/websitedbs/D3310114.nsf/home/Time+Series+Analysis:+The+Basics>.
- [2] N. Sapankevych and R. Sankar, “Time series prediction using support vector machines: A survey,” *IEEE Computational Intelligence Magazine*, vol. 4, no. 2, pp. 24–38, 2009.
- [3] G. Grmanová, P. Laurinec, V. Rozinajová, A. Bou Ezzeddine, M. Lucká, P. Lacko, P. Vrablecová, and P. Návrát, “Incremental Ensemble Learning for Electricity Load Forecasting,” *Acta Polytechnica Hungarica*, vol. 13, no. 2, 2016.
- [4] A. Kumar Singh, S. Khatoon, M. Muazzam, and D. K. Chaturvedi, “An Overview of Electricity Demand Forecasting Techniques,” *NAJDI JOURNAL*, vol. 3, no. 3, 2013.