

Slovenská technická univerzita v Bratislave  
Fakulta informatiky a informačných technológií

Evidenčné číslo: FIIT-111-22222

Matúš Cuper

# Optimalizácia konfiguračných parametrov predikčných metód

Bakalárska práca

Vedúci práce: Ing. Marek Lóderer

máj 2017

Slovenská technická univerzita v Bratislave  
Fakulta informatiky a informačných technológií

Evidenčné číslo: FIIT-111-22222

Matúš Cuper

# Optimalizácia konfiguračných parametrov predikčných metód

Bakalárska práca

Študijný program: Informatika

Študijný odbor: 9.2.1 Informatika

Miesto vypracovania: Ústav informatiky a softvérového inžinierstva, FIIT STU Bratislave

Vedúci práce: Ing. Marek Lóderer

máj 2017

## **Anotácia**

Slovenská technická univerzita v Bratislave

FAKULTA INFORMATIKY A INFORMAČNÝCH TECHNOLOGIÍ

Študijný program: Informatika

Autor: Matúš Cuper

Bakalárska práca: Optimalizácia konfiguračných parametrov predikčných metód

Vedúci práce: Ing. Marek Lóderer

máj 2016

Tu bude text slovenskej anotácie

## **Annotation**

Slovak University of Technology Bratislava

FACULTY OF INFORMATICS AND INFORMATION TECHNOLOGIES

Degree Course: Computer Science

Author: Matúš Cuper

Bachelor thesis: Optimizing configuration parameters of prediction methods

Supervisor: Ing. Marek Lóderer

May 2016

Tu bude text anglickej anotácie

**POĎAKOVANIE**  
Tu bude poďakovanie

## **ČESTNÉ PREHLÁSENIE**

Tu bude prehlásenie

.....  
Matúš Cuper

# Obsah

<b>1</b>	<b>Analýza problému</b>	<b>6</b>
1.1	Časové rady . . . . .	6
1.1.1	Analýza časových radov . . . . .	6
1.1.2	Zložky časových radov . . . . .	6
1.2	Analýza predičných algoritmov . . . . .	7
1.2.1	Lineárna regresia . . . . .	7
1.2.2	Stochastické modely . . . . .	8
1.2.3	Support vector regression . . . . .	9
1.2.4	Rozhodovacie stromy . . . . .	9
1.2.5	Náhodné lesy . . . . .	10
1.2.6	Neurónové siete . . . . .	10
1.2.7	Učenie súborov klasifikátorov . . . . .	11
1.2.8	Exponenciálne hladenie . . . . .	11
1.2.9	Naivné metódy . . . . .	11
1.3	Analýza optimalizačných algoritmov . . . . .	11
1.3.1	Umelá kolónia včiel . . . . .	13
1.3.2	Kolónia mravcov . . . . .	13
1.4	Meranie presnosti predpovedi . . . . .	13
1.4.1	Stredná chyba predpovede . . . . .	14
1.4.2	Stredná absolútna chyba . . . . .	14
1.4.3	Stredná absolútna percentuálna chyba . . . . .	14
1.4.4	Stredná percentuálna chyba . . . . .	14
1.4.5	Stredná štvorcová chyba . . . . .	14
1.4.6	SMAPE . . . . .	14
<b>2</b>	<b>Opis riešenia</b>	<b>15</b>
<b>3</b>	<b>Zhodnotenie</b>	<b>16</b>
<b>4</b>	<b>Technická dokumentácia</b>	<b>17</b>

# 1 Analýza problému

## 1.1 Časové rady

Časový rad je množina dátových bodov nameraná v čase postupne za sebou. Matematicky je definovaný ako množina vektorov  $x(t)$ , kde  $t$  reprezentuje uplynulý čas. Premenná  $x(t)$  je považovaná za náhodnú premennú. Merania v časových radoch sú usporiadané v chronologicky poradí [1].

Časové rady delíme na spojité a diskkrétne. Pozorovania pri spojitých časových radoch sú merané v každej jednotke času, zatiaľ čo diskkrétne obsahujú iba pozorovania v diskrétnych časových bodoch. Hodnoty toku rieky, teploty či koncentrácie látok pri chemickom procese môžu byť zaznamenané ako spojitý časový rad. Naopak, populácia mesta, produkcia spoločnosti alebo kurzy mien reprezentujú diskrétny časový rad. Vtedy sú pozorovania oddelené rovnakými časovými intervalmi, napr. rokom, mesiacom či dňom [1]. V našom prípade sú namerané dáta dostupné každú celú štvrt' hodinu.

### 1.1.1 Analýza časových radov

V praxi je vhodný model napasovaný do daného časového radu a zodpovedajúce parametre sú predpovedané na základe známych dát. Pri predpovedaní časových radov sú dáta z predchádzajúcich meraní zhromažďované a analyzované za účelom navrhnutia vhodného matematického modelu, ktorý zachytáva proces generovania dát pre časové rady. Pomocou tohto modelu sú predpovedané hodnoty budúcich meraní. Takýto prístup je užitočný, keď nemáme veľa poznatkov o vzore v meraniach idúcich za sebou alebo máme model, ktorý poskytuje nedostatočne uspokojivé výsledky [1].

Cieľom predikcií časových radov je predpovedať hodnotu premennej v budúcnosti na základe doteraz nameraných dátových vzoriek. Matematicky zapísané ako

$$\hat{x}(t + \Delta_t) = f(x(t - a), x(t - b), x(t - c), \dots) \quad (1)$$

Hodnota  $\hat{x}$  je predpovedaná ako hodnota diskrétneho časového radu  $x$ . Preto je potrebné nájsť funkciu  $f(x)$ , podobnú funkciu  $\hat{x}$ , ktorá predpovedá hodnotu časového radu v budúcnosti konzistentne a objektívne [2].

Časové rady sú najčastejšie vizualizované ako graf, kde pozorovania sú na osy  $y$  a plynúci čas na osy  $x$ .

### 1.1.2 Zložky časových radov

Pri predpovedaní časových radov ako napr. meraní odberu elektriky vznikajú 2 typy trendov. Prvým typom je trvalá alebo dočasná zmena spôsobená ekonomickými alebo ekologickými faktormi. Druhým typom je sezónna zmena, spôsobená zmenami ročných období a množstvom denného svetla. Môžeme ju pozorovať na úrovni dňov, týždňov alebo rokov. Veličina, ktorú sa snažíme predpovedať postupne mení svoje správanie a model sa tak stáva nepresným. Kvôli tomu je nutné v každom modeli rozdeľovať tieto typy tendencií, aby sme vedeli model zmenám prispôbiť [3].

Vo všeobecnosti sú časové rady zložené zo 4 hlavných zložiek, ktoré môžeme odlíšiť od pozorovaných dát. Jedná sa o trendovú, cyklickú, sezónnu a reziduálnu zložku [1].

**Trendová zložka** predstavuje správanie časového radu v dlhodobom časovom horizonte. Z tohto pohľadu má časový rad tendenciu klesať, rásť alebo stagnovať. Príkladom môže byť nárast populácie či klesajúca úmrtnosť [1].



**Cyklická zložka** je spôsobená zmenami, ktoré sa cyklicky opakujú. Dĺžka periódy je 2 a viac rokov, čo zodpovedá strednodobému časovému horizontu. Táto zložka je zastúpená najmä pri ekonomických časových radoch napríklad podnikateľský cyklus pozostávajúci zo 4 fáz, ktoré sa stále opakujú [1].

**Sezónna zložka** predstavuje kolísanie časových radov počas ročných období. Dôležitými faktormi pri tom sú napr. klimatické podmienky, tradície alebo počasie. Napríklad predaj zmrzliny sa v lete zvyšuje, ale počet predaných lyžiarskych súprav klesá [1].

**Reziduálna zložka** predstavuje veličinu, ktorá nemá žiadny opakovateľný vzor a ani dlhodobý trend. V časových radoch má nepredvídateľný vplyv na pozorovanú veličinu. V štatistike zatiaľ nie je definovaná metóda na jej meranie. Označuje sa aj ako náhodná zložka alebo biely šum. Je spôsobená nepredvídateľnými a nepravidelnými udalosťami [1].

Vo všeobecnosti sa pre tieto 4 zložky používajú 2 rôzne modely. Je to multiplikatívny model a aditívny model.

$$\begin{aligned} Y(t) &= T(t) \times S(t) \times C(t) \times I(t) \\ Y(t) &= T(t) + S(t) + C(t) + I(t) \end{aligned} \quad (2)$$

Vo vzorci 2 predstavuje  $Y(t)$  meranie v čase  $t$ . Premenné  $T(t)$ ,  $S(t)$ ,  $C(t)$  a  $I(t)$  sú zložkami trendu, sezónnosti, cyklu a náhodnosti. Multiplikatívny model je založený na predpoklade, že časové rady môžu byť na sebe závislé a môžu byť ovplyvňované medzi sebou, zatiaľ čo aditívny model predpokladá nezávislosť zložiek [1].

## 1.2 Analýza predikčných algoritmov

Na základe množstva predikčných

### 1.2.1 Lineárna regresia

Najpoužívanější štatistická metóda, ktorá modeluje vzťah závislej premennej a vysvetľujúcej premennej. Závislú premennú predstavuje veličina, ktorú sa snažíme predpovedať, čo je v našom prípade spotreba elektriky. Vysvetľujúca premenná v sebe zahŕňa rôzne faktory, ktoré ovplyvňujú závislú premennú. Môžeme si pod tým predstaviť deň v týždni, počasie, tradície alebo rôzne udalosti, ktoré majú vplyv na predpoveď. [4].

Predpokladajme typický regresný problém. Dáta pozostávajúce z množiny  $n$  meraní majú formát  $\{(x_1, f(x_1)), \dots, (x_n, f(x_n))\}$ . Úlohou regresie je odvodiť funkciu  $\hat{f}$  z dát, kde

$$\hat{f} : X \rightarrow \mathbb{R}, \text{ kde, } \hat{f}(x) = f(x), \forall x \in X, \quad (3)$$

Funkcia  $f$  vo vzorci 3 reprezentuje reálnu neznámu funkciu. Algoritmus použitý na odvodenie funkcie  $\hat{f}$  sa nazýva indukčný algoritmus. Funkcia  $\hat{f}$  sa nazýva model alebo prediktor. Obvykle je úlohou regresie minimalizovať odchýlku funkcie pre štvorcovú chybu, konkrétne strednú štvorcovú chybu MSE [5].

Keďže časový rad pozostáva z viacerých zložiek, môžeme ho zapísať ako funkciu  $L(t)$  definovanú ako

$$L(t) = L_n(t) + \sum a_i x_i(t) + e(t) \quad (4)$$

Vo vzorci 4 funkcia  $L_n(t)$  predstavuje odber elektriky v čase  $t$ . Hodnota  $a_i$  je odhadovaný pomaly meniaci sa koeficient. Faktory  $x_i(t)$  nezávisle vplývajú na spotrebu elektriky. Môže sa jednať napríklad o počasie alebo zvyky ľudí. Komponent  $e(t)$  je biely šum, ktorý má nulovú strednú hodnotu a pevnú varianciu. Číslo  $n$  je počet meraní, obvykle 24 alebo 168, v našom prípade 96 meraní počas jedného dňa [4].

**Lineárna regresná analýza** je štatistická metóda používaná na modelovanie vzťahov, ktoré môžu existovať medzi veličinami. Nachádza súvislosti medzi závislou premennou a potenciálnymi vysvetľujúcimi premennými. Používame pri tom vysvetľujúce premenné, ktoré môžu byť namerané súčasne so závislými premennými alebo aj premenné z úplne iných zdrojov. Regresná analýza môže byť tiež použitá na zlúčenie trendu a sezónnych zložiek do modelu. Keď je raz model vytvorený, môže byť použitý na zásah do spomínaných vzťahov alebo, v prípade dostupnosti vysvetľujúcich premenných, na vytvorenie predikcie [6].

**Viacnásobná lineárna regresia** sa snaží modelovať vzťah medzi dvoma alebo viacerými vysvetľujúcimi premennými a závislou premennou vhodnou lineárnou rovnicou pre pozorované dáta. Výsledný model je vyjadrený ako funkcia viacerých vysvetľujúcich premenných [3].

Túto funkciu môžeme zapísať ako

$$Y(t) = V_t a_t + e_t \quad (5)$$

Vo vzorci 5  $t$  označuje čas, kedy bolo meranie uskutočnené.  $Y(t)$  predstavuje celkový nameraný odber elektriky. Vektor  $V_t$  reprezentuje hodnoty vysvetľujúcich premenných v čase merania. Vysvetľujúce premenné môžu predstavovať meteorologické vplyvy, ekonomický nárast, ceny elektriky či kruhy mien. Chybu modelu v čase  $t$  zapíšeme ako  $e_t$  [4].

## 1.2.2 Stochastické modely

Tieto metódy časových radov sú založené na predpoklade, že dáta majú vnútornú štruktúru, ako napr. autokoreláciu, trend či sezónnu variáciu. Najprv sa precízne zostaví vzor zodpovedajúci dostupným dátam a potom sa na jeho základe predpovie budúca hodnota veličiny [4].

**Autoregresný model** predpovedá budúcu hodnotu premennej ako súčet lineárnej kombinácie  $p$  predchádzajúcich meraní, náhodnej chyby a konštanty. V literatúre sa označuje ako AR (autoregressive model). Matematicky môžeme autoregresný model zapísať ako

$$y_t = c + \sum_{i=1}^p \varphi_i y_{t-i} + \varepsilon_t \quad (6)$$

Vo vzorci 6 hodnota  $y_t$  predstavuje predpovedanú hodnotu v čase  $t$ . Náhodnú chybu v čase  $t$  zapíšeme ako  $\varepsilon_t$ . Hodnoty  $\varphi_i$  sú parametre modelu a  $c$  je konštanta. Konštantou  $p$  označujeme rad modelu [1].

**Model kľzavého priemeru** na rozdiel od autoregresného modelu používa ako vysvetľujúce premenné chyby predchádzajúcich meraní a nie priamo hodnoty. V literatúre sa označuje ako MA (moving average). Matematicky môžeme tento vzťah zapísať ako

$$y_t = \mu + \sum_{j=1}^q \Theta_j \varepsilon_{t-j} + \varepsilon_t \quad (7)$$

Vo vzorci 7 hodnota  $y_t$  predstavuje strednú hodnotu postupnosti meraní v čase  $t$ . Hodnoty  $\Theta_j$  sú parametre modelu a konštantou  $q$  označujeme rad modelu. Vychádzame z predpokladu, že náhodná zložka  $\varepsilon_t$  je biely šum, čo je rovnomerne distribuovaná náhodná premenná, ktorá má nulovú strednú hodnotu a konštantnú varianciu  $\sigma^2$  [1].

**Autoregresívny model kľzavého priemeru** reprezentuje súčasnú hodnotu časového rádu lineárne na základe jeho hodnôt a hodnôt bieleho šumu v predchádzajúcich periódach. V literatúre sa označuje ako ARMA (autoregressive moving average) [4].

Ide o kombináciu autoregresie (AR) a kľzavého priemeru (MA), vhodnú pre modelovanie jednorozmerných časových radov. Matematicky môžeme reprezentovať tento model ako súčet predchádzajúcich modelov

$$y_t = c + \varepsilon_t + \sum_{i=1}^p \varphi_i y_{t-i} + \sum_{j=1}^q \Theta_j \varepsilon_{t-j} \quad (8)$$

Rad modelu určuje  $p$  a  $q$  [1].

**Autoregresívny integrovaný model kľzavého priemeru** je generalizáciou modelu ARMA. V literatúre sa označuje ako ARIMA (autoregressive integrated moving average). Modely typu ARMA môžu byť použité iba na statické časové rady. Mnoho časových radov v praxi vykazuje nestatické správanie a napr. tie, ktoré obsahujú komponenty trendu a sezónnosti. Kvôli tomu bol navrhnutý model ARIMA, ktorý je zahrňa v sebe aj prípady nestatických časových radov. Z nestatických časových radov sa vytvárajú statické pomocou konečného počtu derivovaní dátových bodov. Vzniká tak matematický model, ktorý môžeme zapísať ako

$$\left(1 - \sum_{i=1}^p \varphi_i L^i\right)(1 - L)^d y_t = \left(1 + \sum_{j=1}^q \Theta_j L^j\right) \varepsilon_t \quad (9)$$

Vzorec 9 môžeme zapísať aj jednoduchšie a to

$$\varphi(L)(1 - L)^d y_t = \Theta(L)\varepsilon_t \quad (10)$$

Vo vzorci 9 predstavujú premenné  $p$ ,  $d$  a  $q$  rad autoregresného modelu, modelu kľzavého priemeru a integrovaného modelu. Hodnota  $d$  zodpovedá stupňu derivovania, zvyčajne je rovná 1. V prípade, že  $d = 0$  dostaneme klasický ARMA model. Rovnakým spôsobom vieme dostať modely AR a MA [1].

### 1.2.3 Support vector regression

Support Vector Machine a Support Vector Regression sú založené na štatistickej teórii učenia, nazývanej aj VC teória, podľa svojich autorov, Vapnik a Chervonenkisa [2].

Support Vector Machine je použité na množstvo úloh strojového učenia ako je rozoznávanie vzorov, klasifikácia objektov a v prípade predikcií časových radov to je regresná analýza. Support Vector Regression je postup, ktorého funkcia je predpovedaná pomocou nameraných dát, ktorými je Support Vector Machine postupne natréňované. Toto je odklon od tradičných predpovedí časových radov, v zmysle že Support Vector Machine nepoužíva žiadny model, ale predikciu riadia samotné dáta [2].

Táto predikčná metóda poskytuje malý počet voľných parametrov. Garantuje konvergenciu k ideálnemu riešeniu a môže byť výpočtovo efektívna [2].

### 1.2.4 Rozhodovacie stromy

Rozhodovacie stromy sú jednou z najrozšírenejších učiacich metód. Používajú sa najmä na klasifikáciu, ale v súčasnosti sa využívajú aj na regresiu. Rozhodovací strom je reprezentovaný ako množina uzlov a im prislúchajúcich hrán. Uzly reprezentujú atribúty a výstupné hrany sú vždy označené konkrétnou hodnotou pre atribút, z ktorého vychádzajú. Rozhodovanie začína v koreni stromu a končí po dosiahnutí listového uzla. Pre riešenie jedného problému je možné vytvoriť stromy s rôznym počtom a usporiadaním uzlov. Najlepším riešením je strom s najmenším počtom rozhodovacích uzlov [7].

## Regresný rozhodovací strom

### 1.2.5 Náhodné lesy

Náhodné lesy sú kombináciou predpovedí stromov. Každý strom závisí od hodnoty náhodného vektora s rovnakým rozdelením. Chyba lesu závisí od sily jednotlivých stromov a koreláciou medzi nimi. Náhodný les môžeme definovať ako klasifikátor pozostávajúci z množiny stromov  $\{h(x, \Theta_k), k = 1, 2, \dots\}$ , kde  $\{\Theta_k\}$  sú nezávislé rovnomerne distribuované náhodné vektory a každý strom sa podieľa na hlasom na voľbe triedy vstupu  $x$ . S nárastom počtu stromov hodnota  $\{\Theta_k\}$  konverguje k určitému bodu. Tým je zabezpečené, že náhodné lesy sa s pridávaním počtom stromov nepretrávajú ale veľkosť chyby sa postupne ústáli. Pri výbere náhodného vektora sa snažíme pri zachovaní jeho sily minimalizovať koreláciu, čím zvyšujeme presnosť celého výpočtu [8].

Väčšinou sú náhodné lesy používané na klasifikačné problémy, avšak je možné ich aplikovať aj na regresiu. Regresné náhodné lesy sú tvorené rastom stromov závislých na náhodnom vektore  $\{\Theta\}$ . Prediktor stromu  $h(x, \Theta)$  nadobúda číselné hodnoty narušenie od štíkov tried ako je to pri klasifikačných problémoch. Predpokladáme tréningovú množinu, ktorá je nezávislou distribúciou náhodného vektora  $Y, X$ . Potom môžeme strednú štvorcovú generalizačnú chybu pre číselný prediktor  $h$  matematicky zapísať ako

$$E_{X,Y}(Y - h(X))^2 \quad (11)$$

Prediktor náhodného lesu je tvorený priemerom  $k$  stromov, čo zapíšeme ako  $h(x, \Theta_k)$  [8].

### 1.2.6 Neurónové siete

Neurónové siete sú inšpirované činnosťou mozgu a nervovej sústavy.

Neurónová sieť predstavuje orientovaný graf uzlov. Každý uzol počíta svoj výstup na základe vstupov od susedných uzlov. Výpočet prebieha aplikovaním funkcie, ktorá sa nazýva sigmoid, na vážený súčet vstupov. Uzol neurónovej siete sa označuje ako neurón [9].

Je veľa typov neurónových sietí napríklad viacvrstvové perceptrónové siete, samoriadiace siete, siete s viacerými skrytými vrstvami atď. V každej skrytej vrstve je množstvo neurónov. Hlavnou výhodou je, že väčšina sietí nepotrebuje model. Na druhej strane, tréningovanie obvykle zaberá veľa času. Výstupom siete je lineárna rovnica váh prepojených so vstupom [4].

Najpoužívanejšou neurónovou sieťou je viacvrstvový perceptrón, ktorý pozostáva z uzlov a im prislúchajúcim hranám. Uzly sú zoskupované do rôznych vrstiev. Prvá vrstva je vstupná vrstva, kde počet  $d$  označuje počet vstupných parametrov vstupujúcich do siete. Táto vrstva je následne prepojená hranami so skrytou vrstvou pozostávajúcou z  $h$  uzlov. Tá je potom prepojená s výstupnou vrstvou s  $c$  uzlami. Kvôli tomu sa tieto siete zvyknú označovať aj ako dopredné siete [7].

Elementy skrytých a výstupných vrstiev sú umelé neuróny pozostávajúce z uzlov, viacerých vstupujúcich a jednou výstupnou hranou. Funkciou neurónu je transformovať lineárnu kombináciu vstupov pomocou nelineárnej aktivačnej funkcie, čiže každú vstupnú hranu prenásobiť jej váhou a výsledok týchto súčinov sčítať. Tak dostaneme pre neurón  $j$  vzorec 12 opisujúci lineárnu kombináciu vstupov  $a_j$

$$a_j = \sum_{i=1}^d w_{ji}x_i \quad (12)$$

Príčom váha  $w_{ji}$  označuje váhu medzi neurónom  $i$  na vstupnej vrstve a neurónom  $j$  na skrytej vrstve [7].

Aktivovanie neurónu  $j$  závisí od jeho aktivačnej funkcie  $g(a_j)$ . Jednu z najpoužívanějších aktivačných funkcií, logistickú sigmoidnú funkciu, môžeme matematicky zapísať ako

$$g(a) \equiv \frac{1}{1 + \exp(-a)} \quad (13)$$

Je zrejmé, že funkcia zo vzorca 13 vracia hodnoty v rozmedzí  $(0, 1)$  [7].

### 1.2.7 Učenie súborov klasifikátorov

Používa sa na jednoduchú predikciu. Ak  $h$  je počet meraní, ktoré sú denne dostupné, v deň  $t$  sa vykoná  $h$  predikcií podľa váženého priemeru  $m$  modelmi. Nasledujúci deň sa vypočíta chyba predpovede, na základe ktorej sa znova prepočítajú váhy a každý model sa aktualizuje[3].

Učenie súborov klasifikátorov môžeme rozdeliť na homogénne a heterogénne učenie.

**Homogénne učenie súborov klasifikátorov** Pozostáva z modelov rovnakého typu, ktoré sa učia na rôznych podmnožinách datasetu.

**Heterogénne učenie súborov klasifikátorov** Aplikuje rôzne typy modelov nad rovnakými dátovými množinami[3].

### 1.2.8 Exponenciálne hladenie

### 1.2.9 Naivné metódy

Predpovede sú vytvárané pomocou posledných hodnôt alebo ich priemerov.

**Seasonal naïve method** Poslednú nameranú hodnotu použijeme ako predpoveď pre nasledujúce obdobie. Ak sú naše dáta vysoko závislé od ročného obdobia, je lepšie použiť na predpoveď hodnotu z rovnakého obdobia, napr. z minulého roka [3].

**Naïve average long-term method** Predpokladá, že dáta obsahujú vzory, ktoré nie sú závislé od ročných období. Kvôli tomu sú časové rady lokálne stabilné s pomaly meniacim sa priemerom. Hodnotu, ktorú použijeme ako predpoveď je iba priemerom viacerých posledných hodnôt [3].

**Naïve In median long-term method** Táto metóda je alternatívou k predchádzajúcej metóde. Keďže priemerom nedokáže model dostatočne rýchlo reagovať na rapídne výkyvy a abnormality, lepšie výsledky dosiahneme nahradením priemeru za median posledných  $n$  meraní [3].

## 1.3 Analýza optimalizačných algoritmov

Genetické algoritmy sú biologicky inšpirované algoritmy patriace do triedy evolučných algoritmov. Genetické algoritmy sú stochastické optimalizačné algoritmy s **global search potential**. Od tradičných algoritmov sa líšia hlavne v počte riešení, ktoré sú kandidátmi na najlepšie riešenie. Tradičné vyhľadávacie algoritmy prehľadávajú dôkladne iba jedno riešenie, zatiaľ čo genetické algoritmy hlbšie spracujú viacero kandidátov naraz. Každý kandidát na optimálne riešenie problému je reprezentovaný dátovou štruktúrou, ktorú označujeme pojmom jedinec. Súbor jedincov tvorí populáciu. Začiatok procesu začína náhodnými riešeniami populácie, ktorý sa postupne vylepšuje [10].

Pri genetických algoritmoch sa zavádzajú pojmy ako chromozón, fitness funkcia, kríženie, elitárstvo, operátor reprodukcie či mutácie [10].

Vytvorenie novej generácie prebieha pomocou genetického operátora, a to selekciou, krížením a mutáciou. Proces selekcie vyberie kvalitnejšie chromozóny, ktoré prežijú a vyskytnú sa tak aj v ďalšej generácii. Tiež sa vyberajú nekvalitné chromozóny, ktoré zahynú a nebudú ďalej brané do úvahy [11].

Princíp fungovania genetických algoritmov možno znázorniť v nasledujúcom pseudokóde [10]

---

**Algorithm 1** Pseudokód genetického algoritmu

---

- 1: Náhodne inicializovanie jedincov Inicializácia
  - 2: Vyhodnotenie fitness funkcie pre každého jedinca
  - 3: Výber jedincov pre ďalšiu populáciu na základe fitness funkcie
  - 4: Kríženie jedincov
  - 5: Mutovanie jedincov
  - 6: Kontrola či nebolo nájdené žiadane optimálne riešenie
  - 7: Ukončenie ak sa našlo takéto riešenie, inak opakovanie krokov 2 až 6
  - 8: Koniec
- 

Veľkou výhodou genetických algoritmov je, že mutácia predchádza sklúznutiu do lokálnych miním a rekombinácia chromozónov vedie k rýchlemu približovaniu sa k optimálnemu riešeniu. Napriek týmto výhodám, majú genetické algoritmy aj niekoľko nevýhod [12].

- Reprezentovanie kandidátov je príliš obmedzujúce
- Mutácia a kríženie sú v súčasnosti aplikovateľné iba na chromozóny reprezentované bitovým reťazcom alebo číslami
- Definovanie fitness funkcie je často netriviálnou záležitosťou a jej generalizácia je náročná

**Chromozón** je pomenovanie pre jedinca. V literatúre sa tiež zvykne používať označenie kandidát [13].

**Fitness funkcia** je funkcia určujúca efektívnosť chromozónu, pre ktoré je vypočítaná fitness funkcia. Pri hľadaní optimálneho riešenia sa porovnáva hodnota fitness funkcie aktuálneho riešenia s hodnotou funkcie cieľového riešenia [10, 11].

**Operátor reprodukcie** je obvykle prvý operátor, ktorý sa uplatní na populáciu. Operátor náhodne vyberie reťazce z dvoch chromozónov na párenie [10].

**Kríženie** je operátor **recombination**. Kríženie vykonáva výmenu blokov chromozónov. Z druhého chromozónu je vybraný reťazec náhodnej veľkosti, ktorý sa vymení s rovnako dlhým reťazcom z prvého chromozónu [10].

Vzniká problém ako, čo najvhodnejšie, určiť bod kríženia a vybrať tak najkvalitnejšie bloky chromozónu. Kvôli tomu je potrebné definovať nový element nazývaný väzba, označovaný ako  $d_i$

$$d_i = \frac{a_i + a_{i+1}}{2} \quad (14)$$

Za predpokladu, že chromozón reprezentujeme ako maticu veľkosti  $1 \times N$ , potom väzbu definovanú vzorcom 14 môžeme reprezentovať ako maticu  $1 \times (N - 1)$ . Vypočítaním priemeru

susedných hodnôt aj pre cieľovú maticu a nájdením priemeru matice, určíme body kríženia. Chromozóm rozdělíme na miestach, kde je väzba, čo najmenšia [11].

**Elitárstvo** je to proces pridávania chromozónov s najlepšou hodnotou funkcie fitness priamo do ďalšej populácie. Zaisťuje to, že najlepšie riešenie budúcej generácie bude vždy lepšie alebo pri najhoršom rovnaké ako najlepšie riešenie predchádzajúcej generácie [12].

**Operátor mutácie** sa vykoná po vykonaní operátora reprodukcie. Mutácia chromozómu väčšinou predstavuje operáciu, ktorá s nízkou pravdepodobnosťou invertuje jeden bit v chromozóme [10].

### 1.3.1 Umelá kolónia včiel

ABC algoritmus je pomerne nový medzi rojovými algoritmi. Princíp je založený na biologickom procese, správaní medonosných včiel pri hľadaní potravy. Hlavný mechanizmus ktorým včely optimalizujú množstvo procesov je **waggle dance**, ktorým včely lokalizujú zdroje potravy a nachádzajú ďalšie [10].

Každá včela na pracujúca v roji sa spolupodíela na tvorbe celého systému na globálnej úrovni. Správanie systému je určené lokálnym správaním, kde spolupráca a zladenie jedincov vedie k štruktúrovanému kolaboračnému systému [10].

Algoritmus funguje na princípe, že včely nájdu najviac výnosný zdroj s použitím, čo najmenej energie. **Foragers** (zrejme robotnice hľadajúce zdroj jedla) uvažujú presúvanie sa medzi zdrojmi nektárov na základe kvality alebo zisku zdroju. Algoritmus poskytuje samo-manážovateľné a samo-organizované riešenie, vo svojej podstate decentralizované, pre daný problém [14].

### 1.3.2 Kolónia mravcov

Pri tomto algoritme, mravce tiež opúšťajú mravenisko, kvôli hľadaní zdrojov potravy náhodne. Potom vyhodnotia kvalitu zdroja potravy a donesú ho naspäť do mraveniska. Zanechávajú pri tom na zemi chemické stopy. Sila týchto stôp závisí od kvality nájdeného zdroja potravy. Mnoho výskumov využíva tento algoritmus na riešenie NP problémov, ako napríklad problém obchodných cestujúcich, vyfarbovanie grafov, smerovanie áut alebo plánovacie problémy. Používa sa aj pri **cloud computing** na nájdenie optimálneho riešenia pri plánovaní úloh pre virtuálne servery [14].

Keď mravce hľadajú potravu prvý krát, hľadajú náhodne až kým nenájdu zdroj potravy. Zanechávajú pri tom za sebou chemickú stopu nazývanú feromón, ktorá tak vedie k zdroju. Tá následne priťahuje ostatné mravce k tomuto zdroju potravy. Tento proces pokračuje pokiaľ mravce nenájdu najkratšiu cestu vedúcu ku konkrétnemu zdroju potravy. Najkratšia cesta je určená naakumulovaným množstvom feromónov na ceste k zdroju potravy [14].

## 1.4 Meranie presnosti predpovedí

Pre vyhodnotenie efektívnosti a presnosti modelov je potrebné merať ich vlastnosti tak, aby sme ich vedeli medzi sebou porovnávať. V nasledujúcich spôsoboch merania sú použité pojmy ako aktuálna hodnota  $y_t$ , predpovedaná hodnota  $f_t$  alebo chyba predpovede  $e_t$  definovaná ako  $e_t = y_t - f_t$ . Veľkosť testovacej množiny budeme označovať ako  $n$  [1].

### 1.4.1 Stredná chyba predpovede

V literatúre označovaná ako MFE (mean forecast error). Matematickú funkciu zapísať ako

$$MFE = \frac{1}{n} \sum_{t=1}^n e_t \quad (15)$$

Týmto spôsobom meriame priemernú odchýlku predpovedanej hodnoty od aktuálnej. Zistíme tak smer chyby nazývaný tiež **Forecast bias**. Nevýhodou je, že kladné a záporné chyby sa vynulujú a potom nie je možné zistiť presnú hodnotu chyby. Pri nameraní extrémnych chýb, nie sú nijak špeciálne penalizované. Taktiež hodnota chyby závisí od škály meraní a môže byť ovplyvnená aj transformáciami dát. Dobré predpovede majú hodnotu blízku 0 [1].

### 1.4.2 Stredná absolútna chyba

V literatúre označovaná ako MAE (mean absolute error). Patrí k jedným z najpoužívanějších. Funkciu môžeme zapísať ako

$$MAE = \frac{1}{n} \sum_{t=1}^n |e_t| \quad (16)$$

Týmto spôsobom meriame priemernú absolútnu odchýlku predpovedanej hodnoty od aktuálnej. Zistíme tak celkový rozsah chyby, ktorá nastala počas predpovede. Narozdiel od merania chyby pomocou vzorca 15 sa kladné a záporné chyby nevynulujú, no ani napriek tomu nevieme určiť celkový smer chyby. Na druhej strane tiež nenastáva žiadna penalizácia pri extrémnych chybách, hodnota chyby závisí od škály meraní, môže byť ovplyvnená transformáciami dát a dobré predpovede majú hodnotu čo najbližšiu 0 [1, 15].

### 1.4.3 Stredná absolútna percentuálna chyba

V literatúre označovaná ako MAPE (mean absolute percentage error). Matematicky môžeme túto funkciu zapísať ako

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{e_t}{y_t} \right| \times 100 \quad (17)$$

Pomocou tohto merania chyby získavame percentuálny prehľad o priemernej absolútnej chybe, ktorá sa vyskytla počas predpovedi. Veľkosť chyby nezávisí od škály merania, ale je závislá od transformácií dát. Tiež nie je možné zistiť smer chyby a ani nenastáva žiadna penalizácia pri extrémnych chybách [1].

### 1.4.4 Stredná percentuálna chyba

V označovaná ako MPE (mean percentage error).

### 1.4.5 Stredná štvorcová chyba

V literatúre označovaná ako MSE (mean squared error).

### 1.4.6 SMAPE

V literatúre označovaná ako SMAPE



## **2 Opis riešenia**

### **3 Zhodnotenie**

## **4 Technická dokumentácia**

## Literatúra

- [1] R. Adhikari, *An Introductory Study on Time Series Modeling and Forecasting*. Saarbrücken: LAP LAMBERT Academic Publishing, 2013.
- [2] N. I. Sapankevych and R. Sankar, “Time series prediction using support vector machines: A survey,” *IEEE Computational Intelligence Magazine*, vol. 4, pp. 24–38, May 2009.
- [3] G. Grmanová, P. Laurinec, V. Rozinajová, A. Bou Ezzeddine, M. Lucká, P. Lacko, P. Vrablecová, and P. Návrát, “Incremental Ensemble Learning for Electricity Load Forecasting,” *Acta Polytechnica Hungarica*, vol. 13, no. 2, 2016.
- [4] A. Kumar Singh, S. Khatoon, M. Muazzam, and D. K. Chaturvedi, “An Overview of Electricity Demand Forecasting Techniques,” *Network and Complex Systems*, vol. 3, no. 3, 2013.
- [5] J. a. Mendes-Moreira, C. Soares, A. M. Jorge, and J. F. D. Sousa, “Ensemble approaches for regression: A survey,” *ACM Comput. Surv.*, vol. 45, pp. 10:1–10:40, Dec. 2012.
- [6] L. Liu and G. Hudak, *Forecasting and Time Series Analysis Using the SCA Statistical System*, vol. zv. 1. Scientific computing Associates Corporation, 1992.
- [7] C. J. Merz, *Classification and Regression by Combining Models*. PhD thesis, University of California, 1998. AAI9821450.
- [8] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [9] F. Gruau, L. C. B. Lyon I, O. A. D. D. Doctorat, M. J. Demongeot, E. M. M. Cosnard, M. J. Mazoyer, M. P. Peretto, and M. D. Whitley, “Neural network synthesis using cellular encoding and the genetic algorithm.,” 1994.
- [10] S. D. Chavan, A. V. Kulkarni, T. Khot, and N. Patil, “Bio inspired algorithm for disaster management,” in *2015 International Conference on Energy Systems and Applications*, pp. 776–781, Oct 2015.
- [11] S. Simonova and J. Panus, “Genetic algorithms for optimization of thematic regional clusters,” in *EUROCON 2007 - The International Conference on Computer as a Tool*, pp. 2061–2066, Sept 2007.
- [12] R. V. Deolekar, “Defining parameters for examining effectiveness of genetic algorithm for optimization problems,” in *2016 3rd International Conference on Computing for Sustainable Global Development (INDIACom)*, pp. 1061–1064, March 2016.
- [13] K. Arun and R. Rejimoan, “A survey on network path identification using bio inspired algorithms,” in *2016 2nd International Conference on Advances in Electrical, Electronics, Information, Communication and Bio-Informatics (AEEICB)*, pp. 387–389, Feb 2016.
- [14] A. A. Buhussain, R. E. D. Grande, and A. Boukerche, “Performance analysis of bio-inspired scheduling algorithms for cloud environments,” in *2016 IEEE International Parallel and Distributed Processing Symposium Workshops (IPDPSW)*, pp. 776–785, May 2016.
- [15] P. A. Gutiérrez, M. Pérez-Ortiz, J. Sánchez-Monedero, F. Fernández-Navarro, and C. Hervás-Martínez, “Ordinal regression methods: Survey and experimental study,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 28, pp. 127–146, Jan 2016.