

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE**

**Fakulta informatiky a informačných technológií**

# **Optimalizácia konfiguračných parametrov predikčných metód**

**BAKALÁRSKA PRÁCA**

**2016**

**Matúš Cuper**

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE**

**Fakulta informatiky a informačných technológií**

# **Optimalizácia konfiguračných parametrov predikčných metód**

**BAKALÁRSKA PRÁCA**

Študijný program:

Číslo študijného odboru:

Názov študijného odboru:

Školiace pracovisko:

Vedúci záverečnej práce:

**Bratislava 2016**

**Matúš Cuper**

# Obsah

<b>1</b>	<b>Úvod</b>	<b>2</b>
<b>2</b>	<b>Analýza predičných algoritmov</b>	<b>3</b>
<b>3</b>	<b>Záver</b>	<b>4</b>

# Úvod

Tu bude úvod

## Analýza predičných algoritmov

**Regression model** je funkcia ( $f$ ), ktorou sa snažíme odhadnúť závislú premennú ( $Y$ ), pomocou nezávislej premennej ( $X$ ) a neznámych parametrov ( $Beta$ ), ( $Beta$ ) odhadujeme na základe dát, ( $f$ ) je známa na základe vzťahov medzi ( $Y$ ) a ( $X$ )[1]. najpoužívanejšia štatistická metóda, modeluje vzťah závislej premennej (spotreba elektriky) a nezávislej premennej, čiže ostatných faktorov (počasie, deň v týždni, odoberateľ), spotreba tak môže byť rozdelená na štandardný smer (trend) a trend lineárne závislý od niektorých faktorov vplývajúcich na spotrebu[2].

**Multiple regression model** najpopulárnejšia metóda, často používa na predpoveď spotreby ovplyvnenej množstvom faktorov (meteorologické, cena elektriky, ekonomický nárast)[2].

**Autoregressive model** môže modelovať profil záťaže za predpokladu, že záťaž je lineárnou kombináciou predchádzajúcich záťaží[2].

**Autoregressive Moving-Average model** model reprezentuje súčasnú hodnotu časového rádu lineárne na základe jeho hodnôt a hodnôt bieleho šumu v predchádzajúcich periódach[2].

**Ensemble model** používa sa na jednoduchovú predikciu,  $h$  je počet meraní, ktoré sú denne dostupné, v deň  $t$  sa vykoná  $h$  predikcií podľa váženého priemeru  $m$  modelmi, nasledujúci deň sa vypočíta chyba predpovede, na základe ktorej sa znova prepočítajú váhy a každý model sa aktualizuje[1].

**Seasonal naïve method** poslednú zmeranú hodnotu použijem ako predpoveď alebo pre high seasonal data použijem už nameranú hodnotu z rovnakého obdobia (napr. rok dozadu)[1].

**Naïve average long-term method** je založené na predpoklade non-seasonal patterns, predpokladá, že časové rady sú lokálne stabilné s pomaly meniacim sa priemerom, predpovedaná hodnota je priemerom viacerých hodnôt[1].

**Naïve In median long-term method** je alternatíva k predchádzajúcej metóde, priemer nie je schopný reagovať na rapídne výkyvy a abnormality, lepšia možnosť je preto spraviť median z posledných  $n$  časových radov[1].

**Stochastic Time Series** metódy časových radov sú založené na predpoklade, že dáta majú vnútornú štruktúru, ako napr. autokoreláciu, trend či sezónnu variáciu, najprv sa precízne zostaví vzor zodpovedajúci dostupným dátam a potom sa predpovie hodnota[2].

**Support Vector Machine based Techniques** je metóda analyzujúca dáta a rozpoznávajúca vzory, používaná na roztriedenie a regresnú analýzu, kombinuje zovšeobecnené riadenie s technikou ??????[2].

## **Záver**

Tu bude záver

## Literatúra

- [1] G. Grmanová, P. Laurinec, V. Rozinajová, A. Bou Ezzeddine, M. Lucká, P. Lacko, P. Vrablecová, and P. Návrat, “Incremental Ensemble Learning for Electricity Load Forecasting,” *Acta Polytechnica Hungarica*, vol. 13, no. 2, 2016.
- [2] A. Kumar Singh, S. Khatoon, M. Muazzam, and D. K. Chaturvedi, “An Overview of Electricity Demand Forecasting Techniques,” *NAJDI JOURNAL*, vol. 3, no. 3, 2013.