

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta informatiky a informačných technológií

Optimalizácia konfiguračných parametrov predikčných metód

BAKALÁRSKA PRÁCA

2016

Matúš Cuper

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta informatiky a informačných technológií

Optimalizácia konfiguračných parametrov predikčných metód

BAKALÁRSKA PRÁCA

Študijný program:

Číslo študijného odboru:

Názov študijného odboru:

Školiace pracovisko:

Vedúci záverečnej práce:

Bratislava 2016

Matúš Cuper

Obsah

1	Časové rady	2
1.1	Komponenty časových radov	2
1.1.1	Trendová zložka	2
1.1.2	Cyklická zložka	2
1.1.3	Sezónna zložka	3
1.1.4	Náhodná zložka	3
2	Analýza predičných algoritmov	4
2.1	Lineárna regresia	4
2.1.1	Multiple regression model	4
2.2	Support vector regression	4
2.3	Rozhodovacie stromy	4
2.3.1	Regresný rozhodovací strom	4

Kapitola 1

Časové rady

Časový rad je množina dátových bodov nameraná v čase postupne za sebou. Matematicky je definovaný ako množina vektorov $x(t)$, kde t reprezentuje uplynulý čas. Premenná $x(t)$ je považovaná za náhodnú premennú. Merania v časových radoch sú usporiadané v chronologicky poradí [1].

Časové rady delíme na spojité a diskrétné. Pozorovania pri spojitých časových radoch sú merané v každej jednotke času, zatiaľ čo diskrétné obsahujú iba pozorovania v diskrétnych časových bodoch. Hodnoty toku rieky, teploty či koncentrácie látok pri chemickom procese môžu byť zaznamenané ako spojitý časový rad. Naopak, populácia mesta, produkcia spoločnosti alebo kurzy mien reprezentujú diskrétny časový rad. Vtedy sú pozorovania oddelené rovnakými časovými intervalmi, napr. rokom, mesiacom či dňom. V našom prípade sú namerané dáta dostupné každú celú štvrtú hodinu [1].

Cieľom predikcií časových radov je predpovedať hodnotu premennej v budúcnosti na základe doteraz nameraných dátových vzoriek. Preto je potrebné nájsť funkciu, ktorá predpovedá hodnotu časového radu v budúcnosti konzistentne a objektívne [2].

Časové rady sú najčastejšie vizualizované ako graf, kde pozorovania sú na osy y a plynúci čas na osy x .

1.1 Komponenty časových radov

Vo všeobecnosti sú časové rady ovplyvnené 4 hlavnými komponentmi, ktoré môžu byť oddelené od pozorovaných dát. Jedná sa o trendovú, cyklickú, sezónnu a náhodnú zložku [1].

1.1.1 Trendová zložka

V dlhodobom časovom horizonte majú časové rady tendenciu klesať, rásť alebo stagnovať. Príkladom môže byť nárast populácie či klesajúca úmrtnosť [1].

1.1.2 Cyklická zložka

V strednodobom časovom horizonte sa vyskytujú okolnosti, ktoré spôsobujú cyklické zmeny v časových radoch. Dĺžka periódy je 2 a viac rokov. Táto zložka je zastúpená najmä pri ekonomických časových radoch napr. podnikateľský cyklus pozostávajúci zo 4 fáz, ktoré sa stále opakujú [1].

1.1.3 Sezónna zložka

Ide o kolísanie počas ročných období. Dôležitými faktormi pri tom sú napr. klimatické podmienky, tradície alebo počasie. Napríklad predaj zmrzliny sa v lete zvyšuje, ale počet predaných lyžiarskych súprav klesá [1].

1.1.4 Náhodná zložka

Jedná sa o veličinu, ktorá nemá žiadny opakovateľný vzor a ani dlhodobý trend. V časových radoch má nepredvídateľný vplyv na pozorovanú veličinu. V štatistike zatiaľ nie je definovaná metóda na jej meranie. Je spôsobená nepredvídateľnými a nepravidelnými udalosťami [1].

Pri predpovedaní časových radov ako napr. meraní odberu elektriky vznikajú 2 typy trendov. Prvým typom je trvalá alebo dočasná zmena spôsobená ekonomickými alebo ekologickými faktormi. Druhým typom je sezónna zmena, spôsobená zmenami ročných období a množstvom denného svetla. Môžeme ju pozorovať na úrovni dní, týždňov alebo rokov. Veličina, ktorú sa snažíme predpovedať postupne mení svoje správanie a model sa tak stáva nepresným. Kvôli tomu je nutné v každom modeli rozdeľovať tieto typy tendencií, aby sme vedeli model zmenám prispôbiť [3].

Kapitola 2

Analýza predičných algoritmov

Na základe množstva predikčných

2.1 Lineárna regresia

bars co

2.1.1 Multiple regression model

Viacnásobná regresia sa pokúša modelovať vzťah medzi dvoma alebo viacerými nezávislými premennými a závislou premennou vhodnou lineárnou rovnicou pre pozorované dáta. Výsledný model je vyjadrený ako funkcia viacerých nezávislých premenných a predpoveďou nie je priamka ako je to pri lineárnej regresii [3]. Nezávislé premenné môžu predstavovať meteorologické vplyvy, ekonomický rast, ceny elektriky či kruzy mien [4].

2.2 Support vector regression

Support Vector Machine a Support Vector Regression sú založené na štatistickej teórii učenia, nazývanej aj VC teória, podľa svojich autorov, Vapnik a Chervonenkisa.

Support Vector Machine je použité na množstvo úloh strojového učenia ako je rozoznávanie vzorov, klasifikácia objektov a v prípade predikcií časových radov to je regresná analýza. Support Vector Regression je postup, ktorého funkcia je predpovedaná pomocou nameraných dát, ktorými je Support Vector Machine postupne natrénované. Toto je odklon od tradičných predpovedí časových radov, v zmysle že Support Vector Machine nepoužíva žiadny model, ale predikciu riadia samotné dáta [2].

2.3 Rozhodovacie stromy

Rozhodovacie stromy sú jednou z najrozšírenejších učiacich metód. Používajú sa najmä na klasifikáciu. Rozhodovací strom je reprezentovaný ako množina uzlov a im prislúchajúcich hrán. Uzly reprezentujú atribúty a výstupné hrany sú vždy označené konkrétnou hodnotou pre atribút, z ktorého vychádzajú [5].

2.3.1 Regresný rozhodovací strom

Literatúra

- [1] R. R. A. Agrawal, “An Introductory Study on Time Series Modeling and Forecasting,” *arXiv preprint arXiv:1302.6613*, vol. 1302.6613, pp. 1–68, 2013.
- [2] N. Sapankevych and R. Sankar, “Time series prediction using support vector machines: A survey,” *IEEE Computational Intelligence Magazine*, vol. 4, no. 2, pp. 24–38, 2009.
- [3] G. Grmanová, P. Laurinec, V. Rozinajová, A. Bou Ezzeddine, M. Lucká, P. Lacko, P. Vrablecová, and P. Návrát, “Incremental Ensemble Learning for Electricity Load Forecasting,” *Acta Polytechnica Hungarica*, vol. 13, no. 2, 2016.
- [4] A. Kumar Singh, S. Khatoon, M. Muazzam, and D. K. Chaturvedi, “An Overview of Electricity Demand Forecasting Techniques,” *NAJDI JOURNAL*, vol. 3, no. 3, 2013.
- [5] C. J. Merz, *Classification and regression by combining models*. PhD thesis, University of California, 1998.